LegalGuardian

产品技术文档

v4.3.0 · 2026-08-19 · 西南民族大学法学院参赛团队

目　录

01 **需求分析报告** 02

项目背景 · 问题定义 · 用户分析 · 功能与非功能需求

02 **框架设计说明书** 03

四层模块化架构 · 知识库与脚本引擎 · 数据流设计

03 **测试用例报告** 04

测试策略 · 集成用例 TC001-TC020 · 基准与回归

04 **功能及性能指标** 06

功能指标 · 响应时间 · 实证基线对比 · 可靠性

05 **使用说明手册** 07

安装部署 · 模块使用 · 命令行参考 · 版本与升级

本合集包含 5 份技术文档 · 共 8 页

版本 v4.3.0 · 2026-08-19

第 1 章　需求分析报告

1. 项目背景

大型语言模型在法律场景快速渗透，但实证测评显示其输出存在系统性失效。团队对 DeepSeek、千问 Qwen 完成14 案例 × 2 轮 × 4 维测评：千问虚构法条识别率 0%、DS 许某某案量刑预测误差 71%（预测 3.5 年 vs 实际 6 年）、引导性得分 DS 2.96/5、千问 1.70/5。LegalGuardian 以该实证基线为不可修改的校准锚点，构建"检测—纠正—评分"闭环，落实竞赛铁律：评分可复现（偏差≤0.2）、可校准（对照实证基线）。项目自 v1.0.0 至 v4.3.0 完成 8 个版本迭代（2026-07-29 至 08-19，GitHub 仓库全程可查），各版本演进如下表所示。

版本	日期	核心升级
v1.0.0	07-29	框架创立：AI 法律对话实证校正框架
v2.0.0	07-30	数据奠基：900 案例、1,800 QA、900 RAG、71 案由
v3.0.0	07-31	规模跃升：5,515 法院案例、535 案由、27,575 QA，RAG 检索上线
v4.0.0	07-31	能力成型：18 失效模式、8 大题型评分、法考真题校准
v4.1.0	08-03	体系扩展：F1-F24 全模式、教学大纲合规审核、安全检查器、竞赛场景匹配、基准 16 项
v4.2.0	08-05	质量攻坚：JSON 模块级缓存、主观题归一化、废止法红线修复、去 20 处死代码
v4.2.1	08-17	发布准备：文档结构优化与版本化
v4.3.0	08-17	简洁精进：红线统一、全量校准 C→A、案例检索、三维规制、报告面板；冒烟 41 项全绿

2. 问题定义

- 准确性危机：AI 可能引用虚构或已废止法律（千问将"人格权侵害惩治条例"视为真实法律）
- 深度缺失：结论正确但缺乏深度法理分析，即"浅度正确"
- 引导性不足：指出"问题在哪"但不告诉"怎么解决"（DS 引导性 2.96/5）
- 前提验证盲区：AI 天然相信用户输入，不验证前提假设是否成立
- 用户差异化风险：同一回答对法学生与非专业人士风险等级完全不同
- 教学场景失效（v4.1）：试题歧义、评分偏移、格式违规、跨题矛盾、教学合规偏离

3. 目标用户分析

用户类型	核心需求	风险等级
法学本科生/研究生	深度法理分析、失效模式识别训练、AI 辅助作业	中
法学教师	教学材料审核、AI 输出验证、作业批改辅助	中低
非专业社会人士	通俗解释、醒目风险警示、律师咨询引导	高
AI 工具开发者	三维规制符合性评估、失效模式诊断	中
教务管理者(v4.1)	教学大纲合规审核、教学质量多维评价	中

4. 功能需求

模块	功能	要点
A 审核纠正	24 模式检测 F1-F24	关键词规则+模式匹配，输出概率/严重度/依据；命中即纠正
A 安全检查	8 项检查 C1-C8	法条来源核对、量刑边界、多平台交叉、人工核实标注等
A 四维评分	实测基线对比	准确/时效/逻辑/引导 vs 14 案例实证基线
B 提问优化	5 大模板+场景匹配	陷阱识别（废止法律/量刑预测/未验证前提）+ 问题重写
C 作业评估	8 题型 T1-T8	差异化评分；红线规则 D1=0→总分归零
C 失效检测	24 模式同步检测	作业内嵌失效模式识别 + 改进计划
D 三维评估	T1-T5/E1-E4/L1-L4	技术规范、教育引导、法律保障逐项合规性
E 大纲合规	覆盖率核验（≥80%）	教育部标准+18 必授知识点；缺失清单+修订建议

5. 非功能需求

类别	指标	要求
性能	失效模式检测 / 作业评估	≤5 秒/次 / ≤60 秒/次
可靠性	失效模式覆盖	24/24 全覆盖（F1-F24）
可靠性	虚构法律识别准确率	≥95%
可维护性	知识库更新	JSON 独立于脚本，可直接替换
可扩展性	新增失效模式	candidate_patterns 字段
兼容性	输入格式	.txt / .md / .docx
兼容性	模型基座	Qwen3-Next-80B 等 5 个系列
兼容性	部署平台	AI 龙虾智能体平台

6. 约束条件

约束	要求
模型基座	推理 Qwen3-Next-80B / 嵌入 Qwen3-Embedding-8B / 重排 Qwen3-Reranker-8B / 多模态 Qwen3-VL-32B / 语音 Qwen3-ASR、Qwen3-TTS
平台与算力	须在 AI 龙虾智能体平台部署演示，基于国产芯片算力环境
法律定位	不替代律师/教师，不做终局性法律判断
实证基线	所有纠正建议必须引用 14 案例×2 轮×4 维实证数据
竞赛铁律	评分可复现（偏差≤0.2 分）、评分可校准（对照实证基线）

第 2 章　框架设计说明书

Framework Design Specification

1. 总体架构

LegalGuardian 采用四层模块化架构：知识库层（reference/）、脚本引擎层（scripts/）、逻辑编排层（SKILL.md）、输出模板层（templates/）。层间以 JSON 标准接口通信，实现数据与逻辑完全解耦，知识库可独立更新。

2. 知识库层设计（9 个 JSON 文件）

文件	内容	规模/要点
failure_patterns.json	24 大失效模式知识库	F1-F10 通用/ F11-F18 题型特化/ F19-F24 场景；含严重度、实证证据、纠正策略
curriculum_requirements.json	教育部课程要求	八大领域、18 个必授知识点，供 F24 合规检测
test_baseline.json	实证基线	14 案例 2 轮 4 维（DS 3.84 vs 千问 3.06）
correction_templates.json	提问模板	5 大模板 + 竞赛场景匹配规则
safety_checklist.json	安全检查清单	8 项检查 C1-C8
three_d_regulation.json	三维规制路径	技术 T1-T5 / 教育 E1-E4 / 法律 L1-L4
question_type_rubrics.json	题型评分标准	8 题型 T1-T8 差异化规则
assignment_rubric.json	作业评分标准	五维评分
legal_knowledge_base.json	法条与预警	核心法条 + 废止预警

3. 脚本引擎层设计（15 个 Python 脚本）

脚本	职责
failure_detector.py	F1-F24 逐模式检测引擎，输出概率/严重度/依据
correction_engine.py	F1-F24 全覆盖纠正生成器（实证依据+修正方向+替代表述）

脚本	职责
safety_checker.py	执行 8 项安全检查，输出通过率+总体风险等级
question_type_classifier.py	T1-T8 题型识别与路由
law_assignment_evaluator_v2.py	8 题型统一评估器（红线规则 D1=0 归零）
scoring_engine.py	四维评分
template_matcher.py	5 模板匹配 + 竞赛场景检测（大纲→T1+T4+T5；考试→T3+T5）
answer_key_evaluator.py	答案键验证与批量评分
calibrate_scoring.py	评分校准（对照实证基线）
exam_parser.py	法考真题解析
rag_retriever.py	5,515 案例库确定性检索（v4.3.0）
regulation_assessor.py	三维规制评估（v4.3.0 落地）
report_builder.py	全链路可视化报告（v4.3.0）
legal_db_fetcher.py	法律知识检索
law_assignment_evaluator.py	历史评估器（v4.0）

4. 数据流设计

用户输入（AI 回复/问题/作业/大纲）→ 模块入口 → 知识库加载 → 脚本执行 → JSON → 模板渲染 → 最终报告。模块 A 审核链：failure_detector → correction_engine → safety_checker 三阶段串联；模块E 合规链：大纲解析 → curriculum_requirements 对照 → F24 检测 → 合规报告。

5. 目录结构

目录	内容
scripts/	15 个 Python 脚本（检测/纠正/评分/检索/报告）
reference/	9 个 JSON 知识库（数据与逻辑分离，可独立替换）
templates/	2 个输出模板
benchmark/	黄金标准基准
tests/	集成测试；test_data/ 案例数据
panel/	可视化报告面板（零依赖、离线可用）

6. 版本演进与架构影响

版本	架构变化
v1.0-v2.0	单一脚本流程：检测+纠正，知识库雏形
v3.0-v4.0	数据层独立：RAG 检索、题型评分与考试校准模块成型
v4.1.0	场景扩展：模块E 大纲合规审核、安全检查器、场景门控
v4.3.0	能力升级：rag_retriever / regulation_assessor / report_builder + 可视化面板；精简包

第 3 章　测试用例报告

Test Cases Report

1. 测试策略

三层架构：单元测试（函数级验证）、集成测试（脚本间管道串联）、端到端测试（真实场景模拟）。覆盖 15 个脚本、9 个 JSON 知识库、24 种失效模式（F1-F24），并以全量冒烟测试（41 项，0 FAIL（2026-08-19 全绿））为基线。

2. 核心集成测试用例（TC001-TC010）

编号	模块	名称	结果
TC001	A-基础	法条幻视检测（F1）	通过
TC002	A-进阶	多模式同时检测（F1+F3）	通过
TC003	A-边界	优质回答零误报	通过
TC004	B-基础	废止法律问题优化	通过
TC005	B-进阶	量刑预测优化	通过
TC006	B-实务	实操需求匹配	通过
TC007	C-基础	中等作业评估	通过
TC008	C-红线	红线规则触发	通过
TC009	D-评估	三维规制评估	通过
TC010	ALL	端到端审核链	通过

3. 教学/场景新增用例（TC011-TC020）

编号	模块	名称	结果
TC011	A-安全	safety_checker 8 项检查执行	通过
TC012	C-F11	选项混淆纠正建议生成	通过
TC013	C-F12	采分点遗漏纠正建议生成	通过
TC014	C-F17	三段论缺失纠正建议生成	通过
TC015	E-F24	教学大纲合规偏离检测	通过
TC016	E-F24	核心知识点覆盖率 <80% 触发	通过
TC017	B-竞赛	教学大纲审核→[T1+T4+T5] 匹配	通过
TC018	B-竞赛	考试设计→[T3+T5] 匹配	通过
TC019	检测-F19	试题歧义检测	通过
TC020	检测-F22	跨题一致性检测	通过

4. 基准测试结果（2026-08-05）

指标	结果
题型识别准确率	100%（16/16 全量）
失效模式体系	F1-F24 全覆盖
检测→纠正链路	100% 命中即纠正
教学合规审核	F24 覆盖率阈值 80% 验证通过
综合评级	A（优秀校准，全量 26 项）

5. 回归测试

REG-001~004：基础功能回归；REG-005~010：v4.1.0 新增场景回归，覆盖教学大纲合规、跨题一致性、试题歧义、格式违规、评分偏移、采分点粒度六类 F19-F24 检测验证。

6. 版本迭代测试演进

版本	测试能力演进
v1.0-v2.0	手工验证为主，无自动化测试
v3.0-v4.0	黄金标准基准集建立，回归基线化
v4.1.0	基准扩展至 16 项 + 10 回归；场景门控零误报验证

版本	测试能力演进
v4.2.0	性能与正确性回归：缓存、归一化、红线规则
v4.3.0	冒烟测试 41 项 0 FAIL；全量校准 26 项评级 A

第 4 章　功能及性能指标

Functional & Performance Metrics

1. 功能指标汇总

模块	功能数	核心指标	引入
A：AI 回答审核	8 项	24/24 失效模式覆盖，四维评分+基线对比	v1.0
A：安全检查	8 项	8 项清单执行，风险联动	v4.1
B：提问优化	4 项	5 模板+竞赛场景匹配	v4.1
C：作业评估	5 项	8 题型差异化评分，红线规则 100% 执行	v4.0
D：三维评估	3 项	13 项（T+E+L）全覆盖	v4.3
E：教学合规	3 项	核心知识点覆盖率核验（≥80%）	v4.1
报告面板	4 项	零依赖可视化"数字案卷"，打印/导出 PDF	v4.3
全流程	1 项	检测→纠正→安全→评分→报告管道	v4.3

2. 响应时间

操作	目标	实测
失效模式检测	≤5 秒	≤3 秒
纠正建议生成	≤10 秒	≤8 秒
安全检查执行(v4.1)	≤5 秒	≤2 秒
模板匹配+优化	≤5 秒	≤3 秒
作业评估	≤60 秒	≤45 秒
全流程审核链	≤45 秒	≤30 秒
教学合规审核(v4.1)	≤30 秒	≤20 秒

3. 实证基线对比（1-5 分制）

维度	DS 基线	干问基线	LG 目标	目标差距
准确性	4.03	3.49	≥4.5	+0.47
时效性	4.69	4.13	≥4.5	−0.19（已超额）
逻辑性	3.66	2.93	≥4.0	+0.34
引导性	2.96	1.70	≥3.0	+0.04
综合	3.84	3.06	≥4.0	+0.16

注：目标差距 = LG 目标 − DS 基线，正值表示仍需补齐，负值表示已超出目标；两基线均为同一 14 案例 × 2 轮 × 4 维实证测评结果。

4. 可靠性指标

指标	目标/实测
虚构法律识别率	目标 100%（干问基线 0%）
废止法律标注率	目标 100%
引导性最低阈值	3.0/5（实证最弱维度）
红线规则执行率	100%（D1=0→归零）

指标	目标/实测
评分可复现性	同一输入偏差 ≤0.2 分（确定性规则）
教学合规阈值	核心知识点覆盖率 ≥80%（F24）

5. 资源消耗与可扩展性

指标	当前值	扩展能力
Skill 包大小	约 0.16MB（v4.3.0 精简，原 14MB）	≤1MB
知识库大小	约 0.8MB（9 文件）	≤2MB
模型调用	推理 <2000 token/次	单次审核
失效模式	24 个（F1-F24）	candidate_patterns 扩展
基准测试	16 项 + 10 回归	items 数组追加

第 5 章　使用说明手册

User Manual

1. 概述

LegalGuardian（法律守卫）是基于实证数据的 AI 法律对话审查纠正与法学教育评估 Skill。覆盖 24 种失效模式（F1-F24）、8 大题型（T1-T8）、教学大纲合规审核、三维规制评估与 5,515 案例库检索；面向法学学生/教师、教务管理者、非专业社会人士与 AI 工具开发者。

2. 安装部署

- 前提：AI 龙虾智能体平台账号 + Qwen3 系列模型权限 + Python 3.10+
- 步骤 1：获取 Skill 包（legal-guardian.skill）或 git clone 仓库
- 步骤 2：AI 龙虾平台 → 技能管理 → 上传技能 → 选择 .skill 文件 → 确认
- 步骤 3：验证——对话中提及法律问题，确认 Skill 自动激活

3. 核心模块使用指南

模块	使用方式	关键输出
A 审核纠正	粘贴 AI 回答，附言"请审核这段 AI 法律回答"	24 模式检测报告+纠正建议+安全等级
B 提问优化	写出原始问题，附言"请优化提问方式"	陷阱识别+推荐模板+优化后问题
C 作业评估	python scripts/law_assignment_evaluator_v2.py 作业.docx	8 题型评分+红线判定+改进计划
D 三维评估	python scripts/regulation_assessor.py --text "功能描述"	T1-T5/E1-E4/L1-L4 逐项状态+雷达图
E 大纲合规	粘贴大纲，附言"请审核教学大纲合规性"	覆盖率+缺失知识点清单+修订建议
报告面板	python scripts/report_builder.py 输入.txt --out panel/report.json	双击 panel/report_panel.html 可视化

4. 安全检查（v4.1.0 新增）

对所有审核结果执行 8 项安全检查（C1-C8）：法条来源核对、罪名定性反向思考、量刑预测风险边界、多平台交叉验证、遗漏争点、需人工核实标注、不替代律师、计算一致性。

5. 命令行快速参考

```
# 模块A —— AI 回答审核
python scripts/failure_detector.py input.txt
python scripts/correction_engine.py result.json
python scripts/safety_checker.py input.txt --detections result.json
# 模块B —— 提问优化
python scripts/template_matcher.py "原始问题"
# 模块C —— 作业评估
python scripts/law_assignment_evaluator_v2.py 作业.docx
# 模块E —— 大纲合规（检测 F24）
```

```
python scripts/failure_detector.py 大纲.txt
# 案例检索（v4.3.0）
python scripts/rag_retriever.py --query "民间借贷 利息上限" -k 5
# 三维规制评估（v4.3.0）
python scripts/regulation_assessor.py --text "工具功能描述"
# 报告面板（v4.3.0）
python scripts/report_builder.py 输入.txt --out panel/demo_report.json && start panel/report_panel.html
```

6. 版本与升级说明

当前版本 v4.3.0（2026-08-17）。自 v1.0.0 起历经 8 个版本迭代（GitHub 仓库 phillnarsoeer/legal-guardian 全程可查）：v1.0 框架创立 → v2.0/v3.0 数据奠基（900→5,515 案例）→ v4.0 能力成型（18 模式/8 题型）→ v4.1 体系扩展（F1-F24/大纲合规/安全检查）→ v4.2 质量攻坚（性能/正确性/重构）→ v4.3 简洁精进（红线统一/案例检索/三维规制/报告面板）。

- 升级步骤：以仓库最新版替换 scripts/ 与 reference/（结构向后兼容，旧版输出可直接导入报告面板）
- 版本核对：检查 manifest.yaml 的 version 字段与 SKILL.md 头部 frontmatter 一致

7. 常见问题

- Q：Skill 未自动激活？ A：检查 manifest.yaml 的 description 关键词，确认 Skill 已启用
- Q：检测到但无纠正建议？ A：确认 reference/ 下所有 JSON 知识库文件完整
- Q：如何更新法律知识？ A：直接编辑 reference/legal_knowledge_base.json
- Q：如何更新教学合规标准？ A：直接编辑 reference/curriculum_requirements.json

— 文档完 —